IBM DATA SCIENCE CAPSTONE · PROYECTO FINAL

Machine Learning · 83.33% de exactitud

Predicción de Aterrizaje de la Primera Etapa del Falcon 9

Análisis predictivo de reutilización de cohetes SpaceX para la optimización de costos de lanzamiento espacial y licitaciones competitivas.

AUTOR
Luis Ernesto Leiva Vázquez

REPOSITORIO DEL PROYECTO
github.com/96092314166/IBM-Machine-Learning-Course

Repositorio público: 8 notebooks (.ipynb) y 1 aplicación Python (spacex-dash-app.py)

CONTENIDO

Tabla de contenido y mapa del repositorio

N.º	SECCIÓN	ARCHIVO EN GITHUB	DIAPOSITIVA
1	Resumen ejecutivo e introducción	README.md	3–4
2	Recolección con API REST	`jupyter-labs-spacex-data-collection-api.ipynb`	6
3	Web scraping de Wikipedia	`jupyter-labs-webscraping.ipynb`	7
4	Data wrangling	`labs-jupyter-spacex-Data wrangling.ipynb`	8
5	EDA con visualización (metodología y resultados)	`edadataviz.ipynb`	9–13
6	EDA con SQL (10 consultas)	`jupyter-labs-eda-sql-coursera_sqllite.ipynb`	14–19
7	Mapa interactivo con Folium	`lab_jupyter_launch_site_location.ipynb`	20–25
8	Dashboard con Plotly Dash	`spacex-dash-app.py`	26–28
9	Análisis predictivo (clasificación) y resultados	`SpaceX_Machine Learning Prediction_Part_5.ipynb`	29–32
10	Discusión, conclusiones y apéndice	github.com/96092314166/IBM-Machine-Learning-Course	33–36

RESUMEN EJECUTIVO

Resumen ejecutivo: metodología y resultados

Problema

SpaceX ofrece lanzamientos Falcon 9 a $62M frente a $165M+ de otros proveedores gracias a reutilizar la primera etapa. Predecir si aterrizará permite estimar el costo real y preparar ofertas competitivas.

Metodología

Datos de la API REST de SpaceX y web scraping de Wikipedia (90 misiones Falcon 9), preparación y one-hot, EDA visual, 10 consultas SQL, mapa Folium, dashboard Plotly Dash y 4 clasificadores con GridSearchCV.

Resultados EDA y SQL

Éxito 0% hasta 2013 y creciente hasta ≈84–90% en 2019–2020. Primer aterrizaje en tierra: 2015-12-22. 100 misiones exitosas vs 1 fallida.

Analítica interactiva

De 56 lanzamientos, 24 tuvieron éxito. KSC LC-39A tiene la mayor tasa (76.9%, 10 de 13) y el 41.7% de todos los éxitos.

Modelado predictivo

Regresión Logística, SVM y KNN alcanzan 83.33% de exactitud en prueba (15 de 18); el árbol, 66.67%.

Conclusión: El aterrizaje se puede predecir con 83.33% de exactitud, útil para estimar costos de lanzamiento.

CONTEXTO COMERCIAL

Introducción: disrupción económica y preguntas clave

$62M

Costo anunciado de un lanzamiento SpaceX Falcon 9

$165M+

Costo de otros proveedores por lanzamiento

Gran parte del ahorro proviene de reutilizar la primera etapa. Si se puede predecir que aterrizará, se puede estimar el costo del lanzamiento y preparar una oferta competitiva frente a SpaceX.

Preguntas de investigación

Factores de carga: ¿cómo afectan la masa de la carga útil y la órbita a la probabilidad de recuperar el propulsor?

Ubicación: ¿qué sitios de lanzamiento presentan mayor éxito y qué factores geográficos comparten (costa, vías, distancia a ciudades)?

Evolución: ¿cómo cambió la tasa de aterrizajes exitosos con los años y las versiones del propulsor?

Predicción: ¿es posible predecir el aterrizaje con Machine Learning con alta exactitud?

METODOLOGÍA

Flujo analítico de extremo a extremo

1 **Recolección**
API REST de SpaceX y web scraping de Wikipedia

2 **Preparación**
Limpieza, imputación, variable objetivo y one-hot

3 **EDA visual**
Éxito por año, carga, órbita y sitio

4 **EDA con SQL**
10 consultas sobre SQLite

5 **Folium y Dash**
Mapas interactivos y dashboard

6 **Modelado ML**
4 clasificadores con GridSearchCV

Herramientas

Python, pandas, NumPy, requests, BeautifulSoup, SQLite + SQL magic, Folium, Plotly Dash, scikit-learn, Matplotlib y Seaborn.

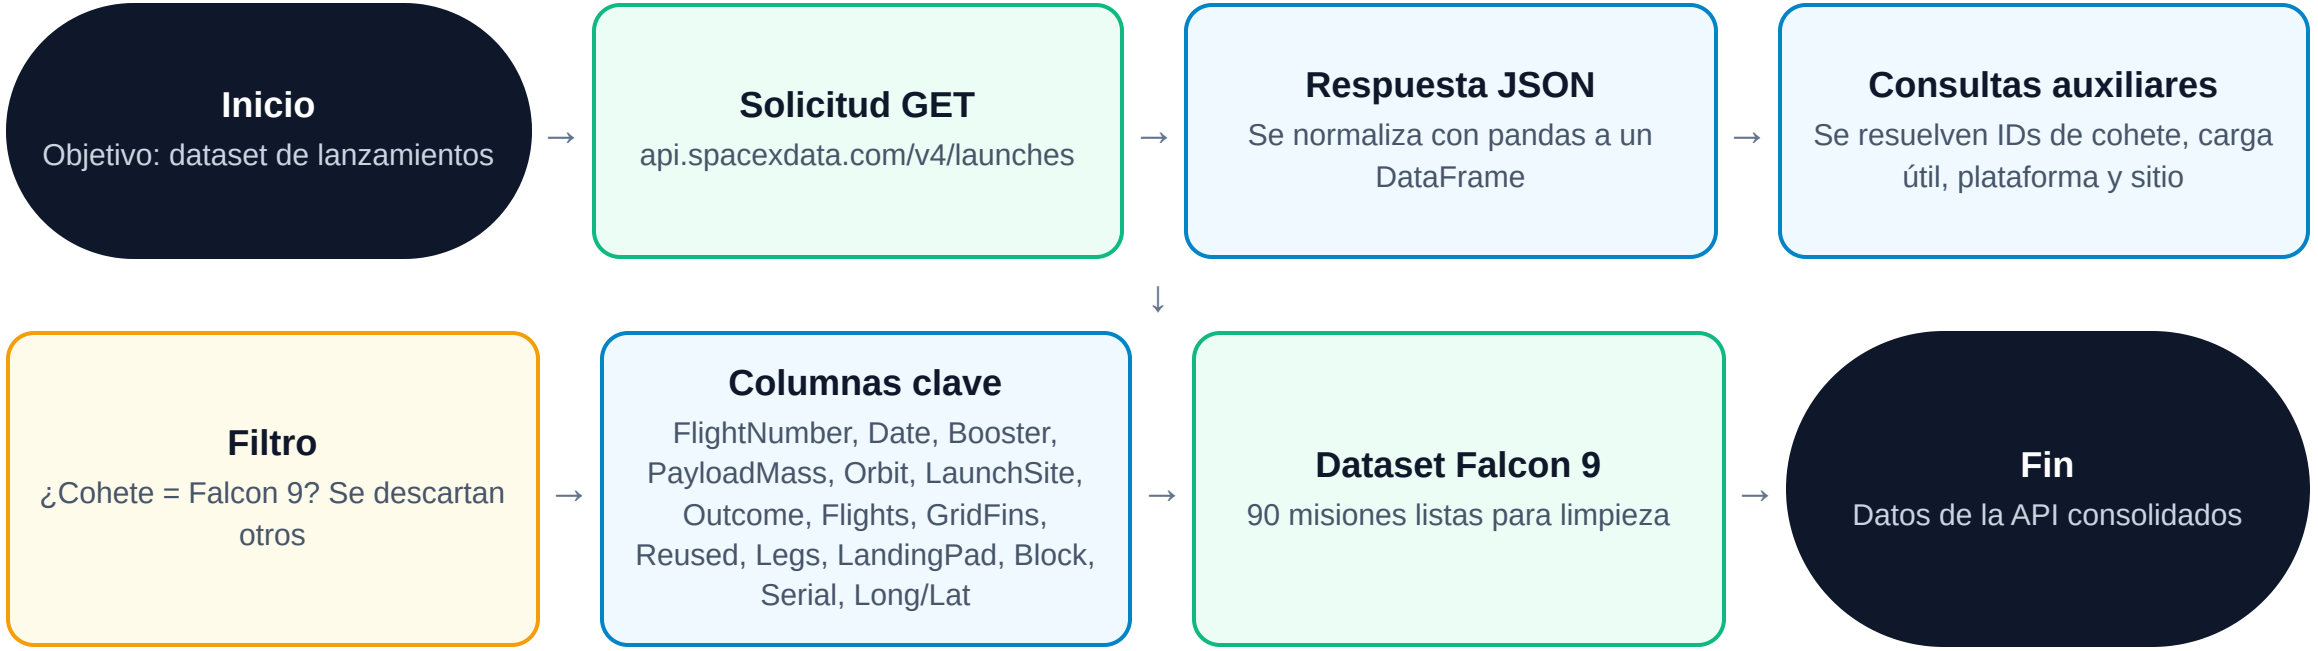
Variable objetivo

`Class` = 1 si la primera etapa aterriza con éxito y 0 en caso contrario.

Entregables

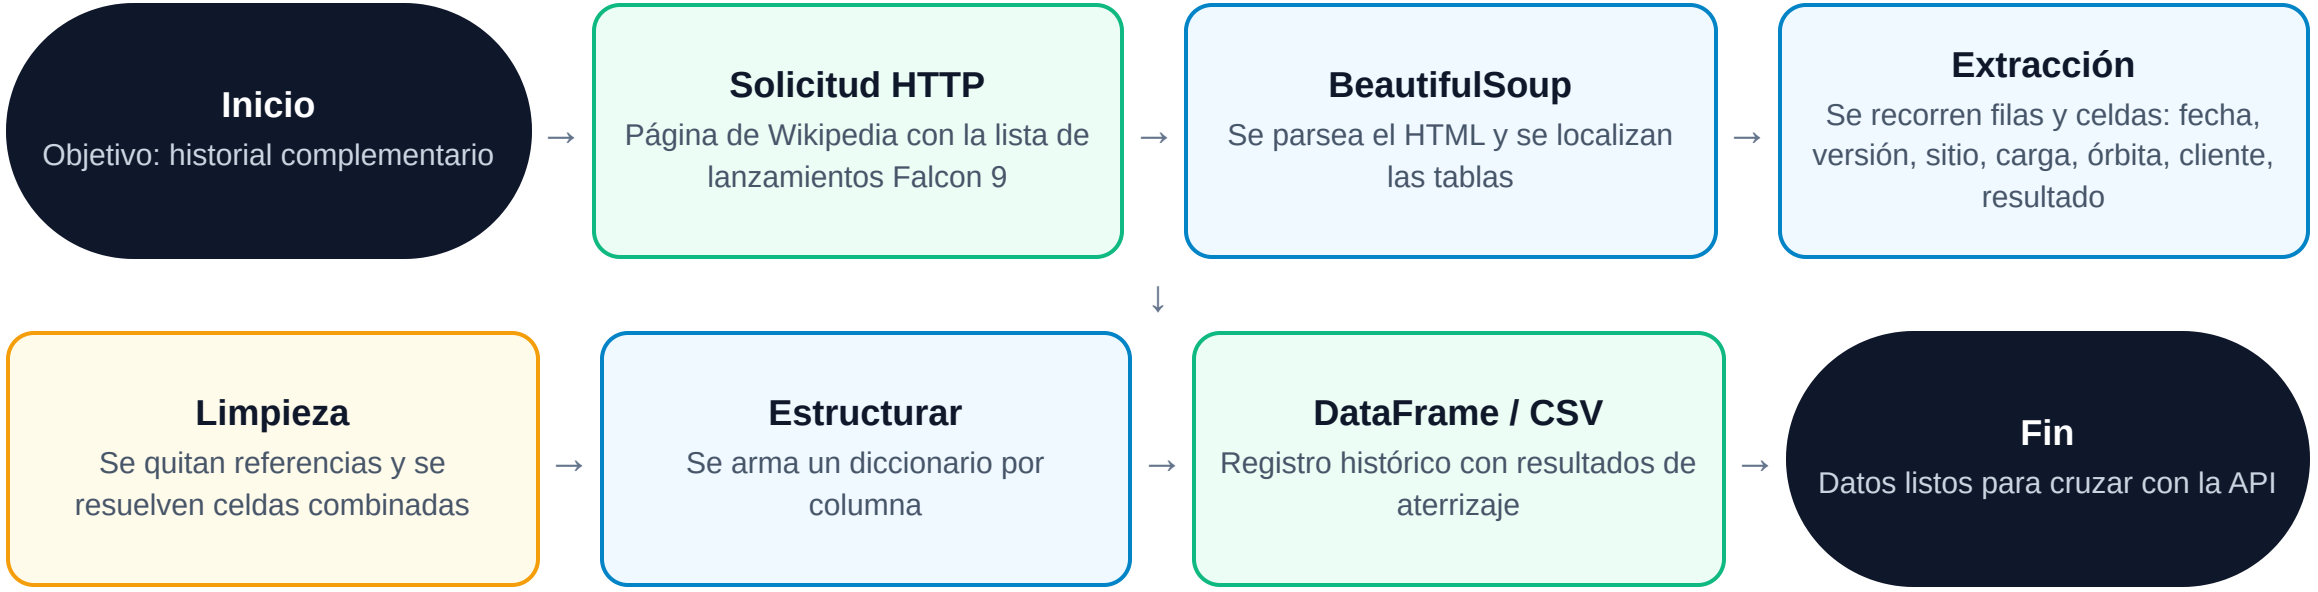
8 notebooks (.ipynb), la app `spacex-dash-app.py` y un README en el repositorio público de GitHub (mapa completo en la diapositiva 2).

Recolección con la API REST de SpaceX: diagrama de flujo



La API entrega identificadores en lugar de nombres; por eso se consultan los endpoints secundarios antes de armar el DataFrame. Código completo en el repositorio de GitHub (`jupyter-labs-spacex-data-collection-api.ipynb`).

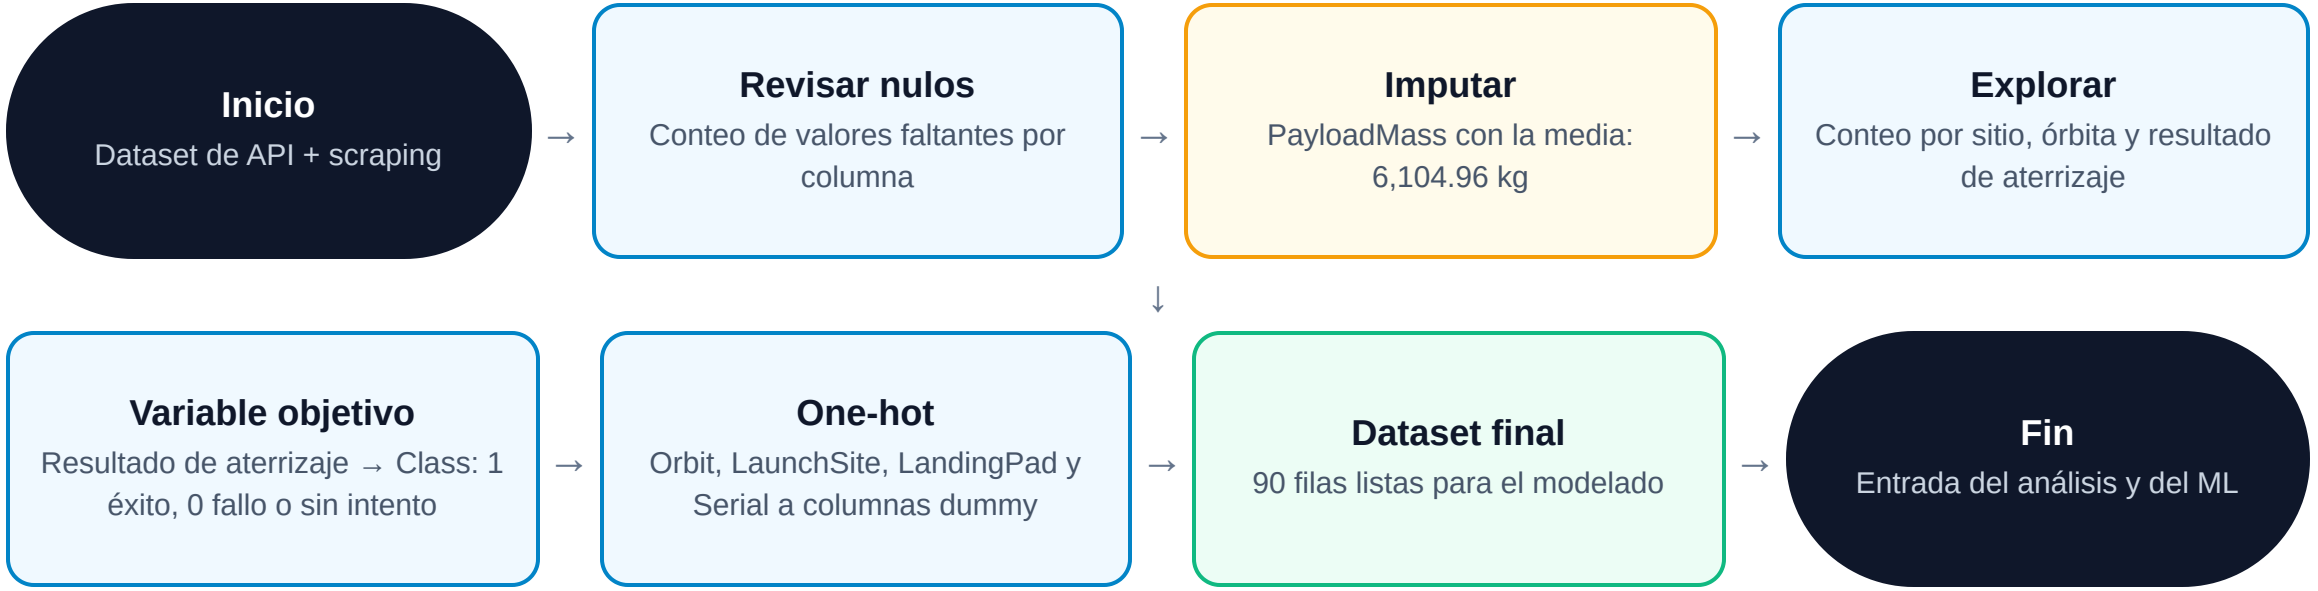
Web scraping de Wikipedia: diagrama de flujo



El scraping complementa a la API con el historial por misión (resultado de la misión y del aterrizaje). Código completo en el repositorio de GitHub (`jupyter-labs-webscraping.ipynb`).

INGENIERÍA DE DATOS

Preparación y transformación (data wrangling): diagrama de flujo



90
misiones Falcon 9

6,104.96 kg
masa promedio imputada

0 / 1
variable objetivo Class

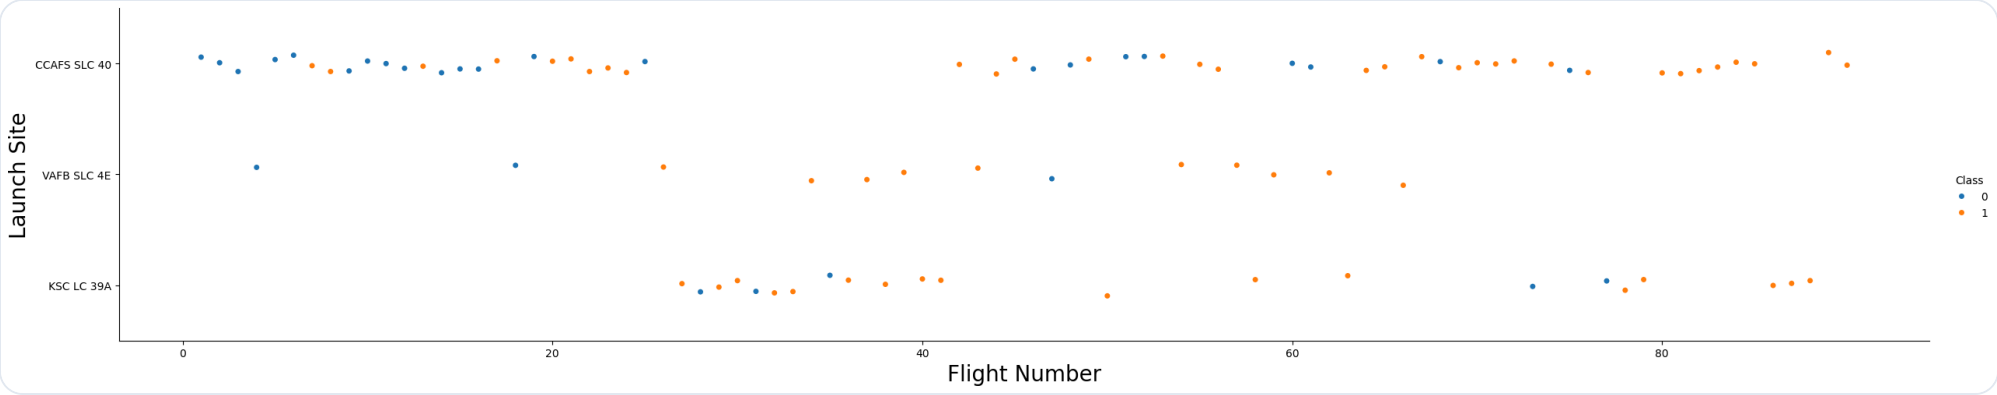
METODOLOGÍA DE EDA

EDA con visualización: qué gráficos se construyeron y por qué

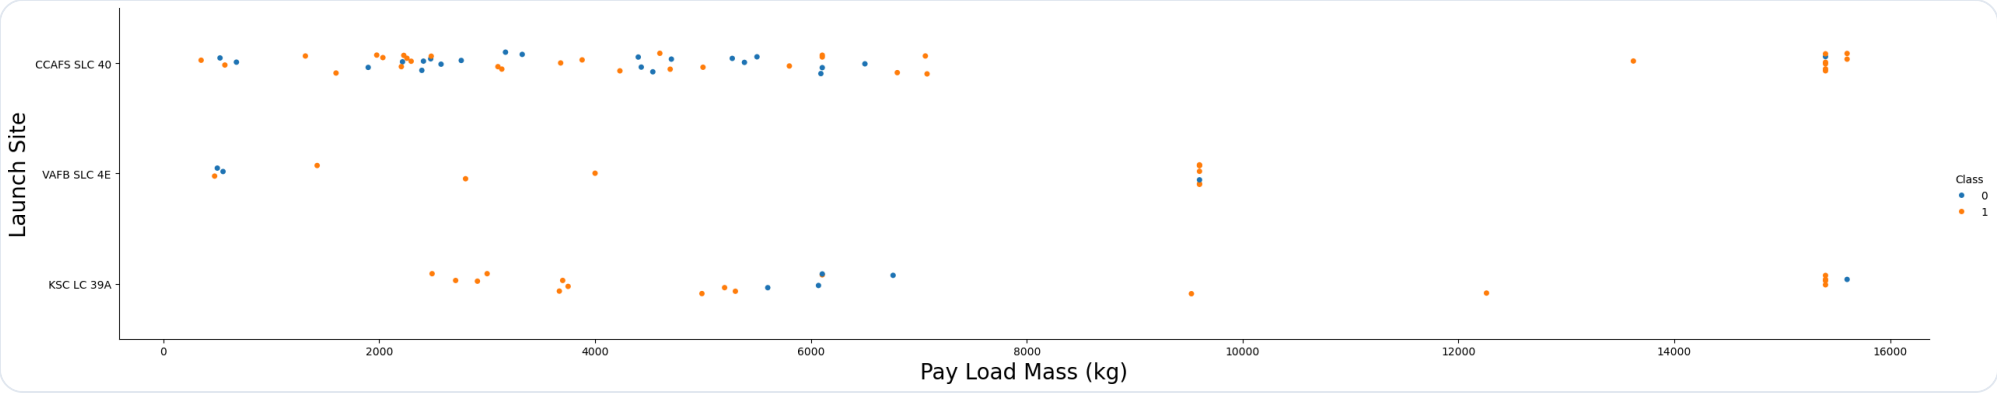
GRÁFICO	QUÉ MUESTRA	POR QUÉ SE CONSTRUYÓ
Número de vuelo vs sitio (dispersión por Class)	Éxito/fallo de cada vuelo en cada plataforma a lo largo del tiempo	Ver si la experiencia acumulada mejora el aterrizaje en cada sitio
Carga útil vs sitio (dispersión por Class)	Masa de la carga y resultado por plataforma	Identificar rangos de carga que optimizan la tasa de éxito
Tasa de éxito por órbita (barras)	Proporción de éxito para LEO, GTO, ISS, VLEO, SSO, GEO, HEO, ES-L1…	Comparar la efectividad entre tipos de órbita
Tendencia anual (líneas)	Tasa de éxito por año, de 2010 a 2020	Medir la evolución del aprendizaje técnico

Los gráficos se construyeron con Seaborn y Matplotlib. Las columnas categóricas resultantes alimentan la ingeniería de características (one-hot) del modelo.

Número de vuelo, carga útil y sitio de lanzamiento



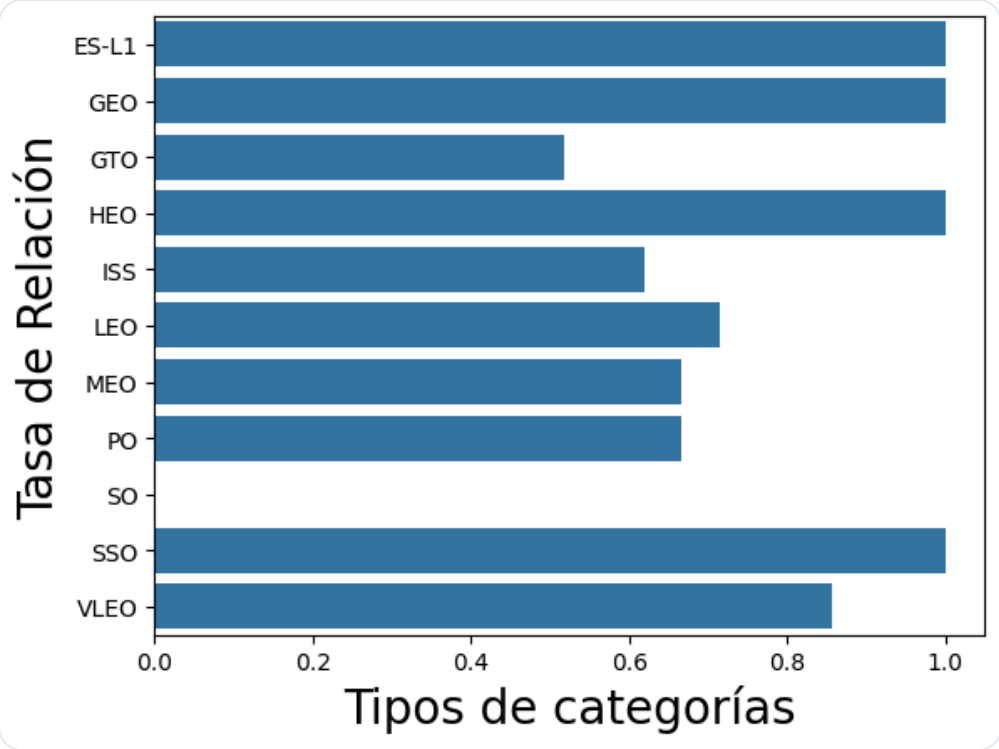
Número de vuelo vs sitio (color = Class). A mayor número de vuelo, mayor probabilidad de aterrizaje exitoso en los tres sitios.



Carga útil vs sitio (color = Class). VAFB SLC-4E no tiene lanzamientos con cargas de más de 10,000 kg.

Salidas del notebook `edadataviz.ipynb`. Insight: el éxito aumenta con la experiencia acumulada (número de vuelo) en todos los sitios; la carga define qué misiones se lanzan desde cada plataforma.

Tasa de éxito por tipo de órbita



Eje horizontal: tasa de éxito (0 a 1); eje vertical: tipo de órbita.

Órbitas con 100% de éxito

ES-L1, GEO, HEO y SSO lograron aterrizar siempre en la muestra.

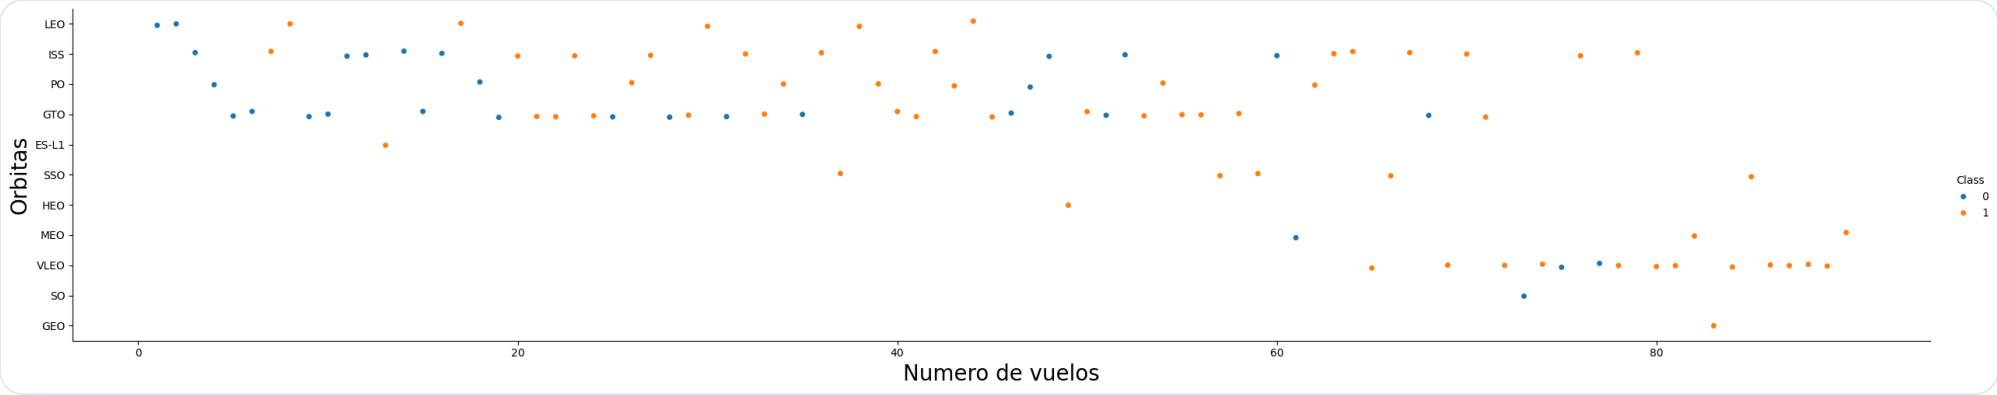
Órbitas intermedias

VLEO (≈86%), LEO (≈71%), MEO y PO (≈67%), ISS (≈62%) y GTO (≈52%).

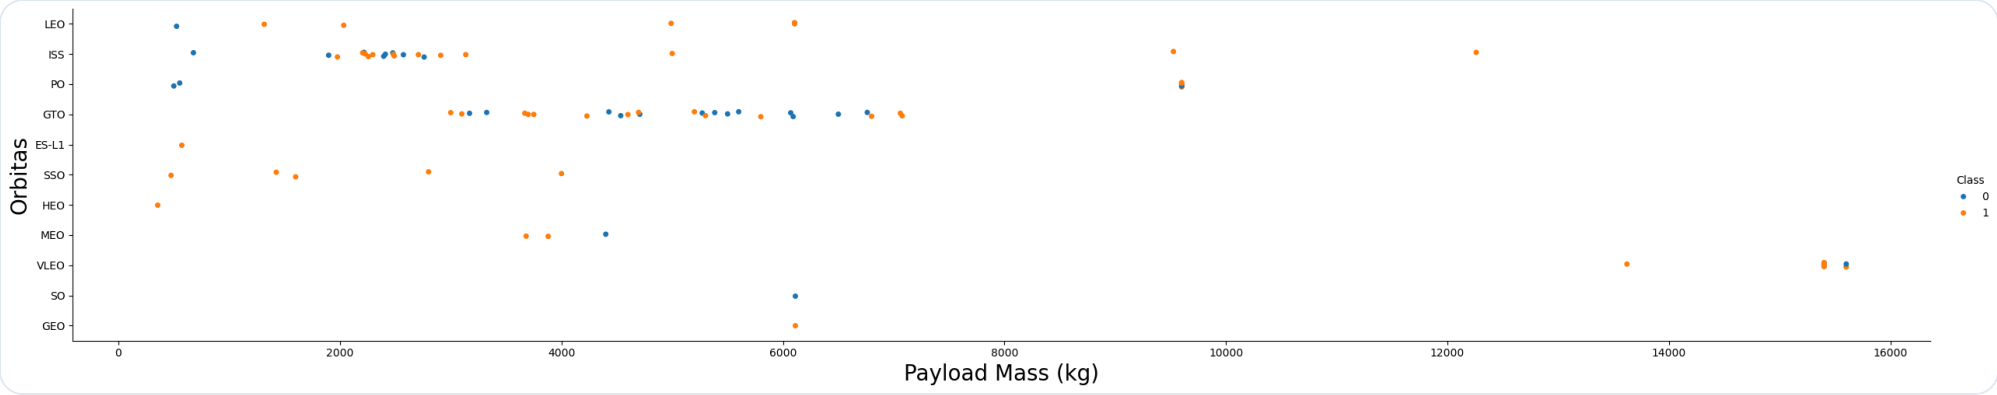
Sin éxito

La órbita **SO** no registra aterrizajes exitosos (muestra muy pequeña).

Número de vuelo y carga útil según la órbita



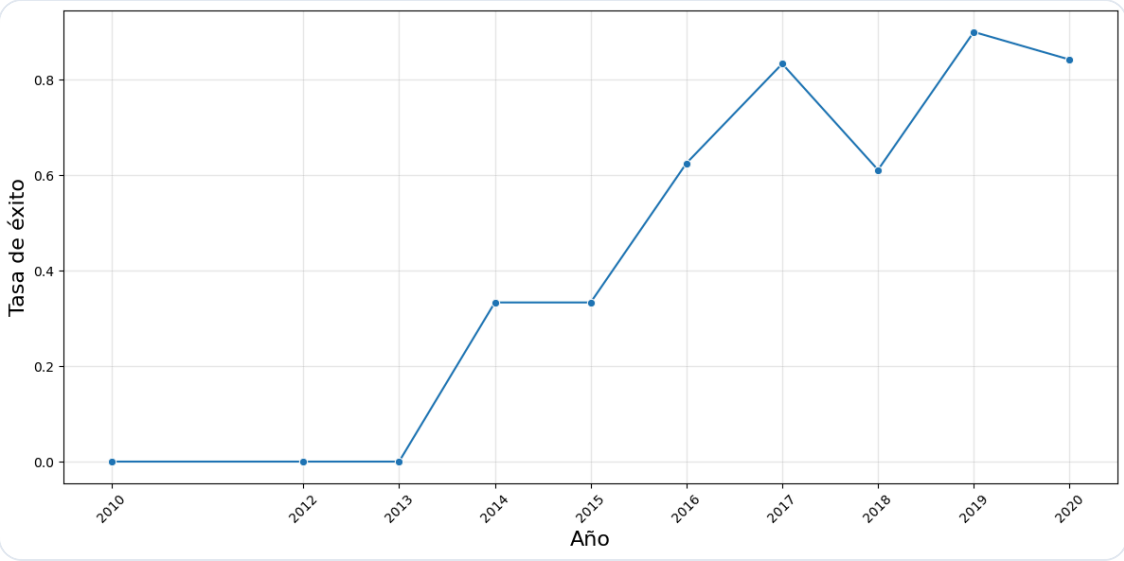
Número de vuelo vs órbita (color = Class). En LEO el éxito se relaciona con el número de vuelo; en GTO no hay relación clara.



Carga útil vs órbita (color = Class). Con cargas pesadas hay más aterrizajes exitosos en PO, LEO e ISS; en GTO se mezclan éxitos y fallos.

Interpretación: GTO es la órbita donde el éxito se explica peor por vuelo o por carga, por lo que resulta la más difícil de predecir.

Tendencia anual del éxito y relación vuelo–carga



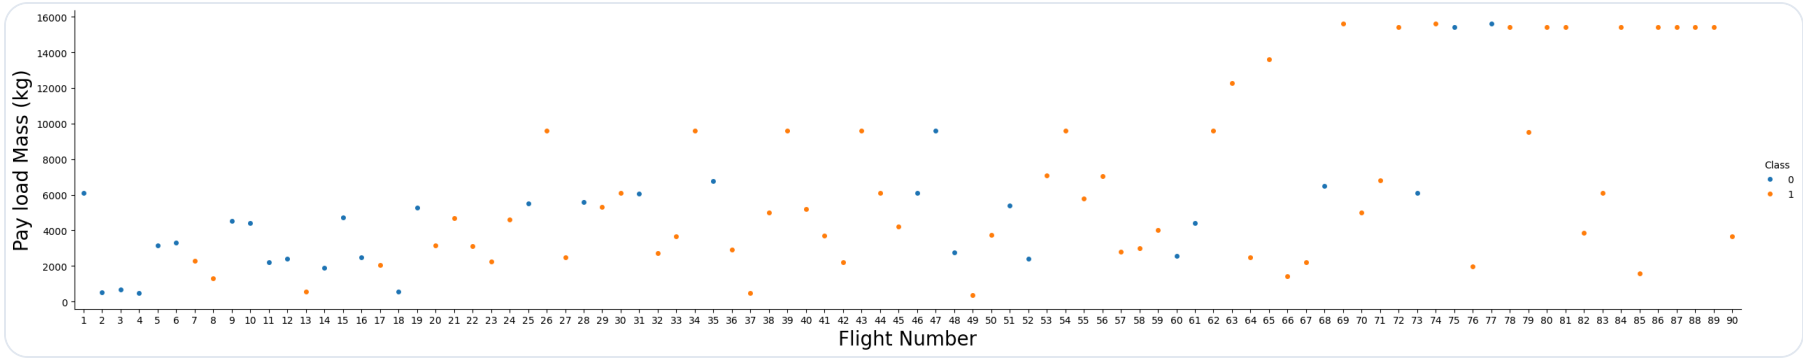
Tasa de éxito por año.

Tendencia anual

El éxito es 0% hasta 2013 y crece hasta 2020: ≈33% en 2014–2015, ≈83% en 2017 y ≈84–90% en 2019–2020, con una caída en 2018 (≈61%).

Vuelo, carga y resultado

A medida que aumenta el número de vuelo, la primera etapa aterriza con más frecuencia, incluso con cargas más pesadas.



Número de vuelo vs masa de carga (color = Class).

ANÁLISIS CON SQL · PREPARACIÓN

Base de datos y tareas

Carga del dataset

El CSV de SpaceX se carga con `pandas.to_sql` en SQLite (tabla `SPACEXTBL`) y se crea `SPACEXTABLE` sin filas vacías:

```
CREATE TABLE SPACEXTABLE AS
SELECT * FROM SPACEXTBL
WHERE Date IS NOT NULL
```

Columnas principales

Date, Time (UTC), Booster_Version, Launch_Site, Payload, PAYLOAD_MASS__KG_, Orbit, Customer, Mission_Outcome y Landing_Outcome.

Las 10 tareas resueltas

1) Sitios únicos · 2) Registros CCA% · 3) Carga total NASA (CRS) · 4) Masa promedio · 5) Primer aterrizaje en tierra · 6) Boosters en drone ship con carga 4000–6000 kg · 7) Resultados de misión · 8) Carga máxima · 9) Fallos en drone ship de 2015 · 10) Ranking de aterrizajes 2010–2017.

SQLite no tiene nombres de mes: se usa `substr(Date, 6, 2)` para el mes y `substr(Date, 0, 5)` para el año.

Tareas 1–3: sitios, registros CCA y carga NASA (CRS)

OBJETIVO	CONSULTA SQL	RESULTADO
1. Sitios únicos de lanzamiento	`SELECT DISTINCT Launch_Site FROM SPACEXTABLE`	CCAFS LC-40, VAFB SLC-4E, KSC LC-39A, CCAFS SLC-40
2. Cinco registros con sitio que inicia con 'CCA'	`SELECT * FROM SPACEXTABLE WHERE Launch_Site LIKE 'CCA%' LIMIT 5`	Cinco primeras misiones, todas en CCAFS LC-40 (2010-06-04 a 2013-03-01)
3. Carga total de NASA (CRS)	`SELECT SUM(PAYLOAD_MASS__KG_) AS Total_weight FROM SPACEXTABLE WHERE Customer = 'NASA (CRS)'`	**Total_weight = 45,596 kg**

FECHA	BOOSTER	SITIO	CARGA ÚTIL	MASA (KG)	ÓRBITA	ATERRIZAJE
2010-06-04	F9 v1.0 B0003	CCAFS LC-40	Dragon Qualification Unit	0	LEO	Failure (parachute)
2010-12-08	F9 v1.0 B0004	CCAFS LC-40	Dragon demo flight C1	0	LEO (ISS)	Failure (parachute)
2012-05-22	F9 v1.0 B0005	CCAFS LC-40	Dragon demo flight C2	525	LEO (ISS)	No attempt
2012-10-08	F9 v1.0 B0006	CCAFS LC-40	SpaceX CRS-1	500	LEO (ISS)	No attempt
2013-03-01	F9 v1.0 B0007	CCAFS LC-40	SpaceX CRS-2	677	LEO (ISS)	No attempt

Tareas 4–6: masa promedio F9 v1.1, primer aterrizaje en tierra y boosters

OBJETIVO	CONSULTA SQL	RESULTADO
4. Masa promedio de carga de F9 v1.1	`SELECT AVG(PAYLOAD_MASS__KG_) AS Average_weight FROM SPACEXTABLE WHERE Booster_Version LIKE 'F9 v1.1%'`	**Average_weight = 2,928.4 kg**
5. Primer aterrizaje exitoso en tierra	`SELECT MIN(Date) FROM SPACEXTABLE WHERE Landing_Outcome = 'Success (ground pad)'`	**2015-12-22 (hito histórico)**
6. Boosters con éxito en drone ship y carga entre 4000 y 6000 kg	`SELECT DISTINCT Booster_Version FROM SPACEXTABLE WHERE Landing_Outcome = 'Success (drone ship)' AND PAYLOAD_MASS__KG_ > 4000 AND PAYLOAD_MASS__KG_ < 6000`	F9 FT B1022, F9 FT B1026, F9 FT B1021.2, F9 FT B1031.2

Masa promedio de carga, F9 v1.1

2,928.4 kg

Primer aterrizaje exitoso en tierra

2015-12-22

Tareas 7–8: resultados de misión y carga máxima

OBJETIVO	CONSULTA SQL	RESULTADO
7. Total de misiones exitosas y fallidas	`SELECT COUNT(*) FILTER (WHERE Mission_Outcome LIKE '%Success%') AS success_total, COUNT(*) FILTER (WHERE Mission_Outcome LIKE '%Failure%') AS failure_total FROM SPACEXTABLE`	**100 exitosas vs 1 fallida**
8. Boosters con la carga máxima (subconsulta)	`SELECT Booster_Version FROM SPACEXTABLE WHERE PAYLOAD_MASS__KG_ = (SELECT MAX(PAYLOAD_MASS__KG_) FROM SPACEXTABLE)`	12 versiones de la familia F9 B5

Misiones (Mission_Outcome)

100 exitosas vs **1** fallida

Boosters con la carga máxima

F9 B5 B1048.4 · B1049.4 · B1051.3 · B1056.4 · B1048.5 · B1051.4 · B1049.5 · B1060.2 · B1058.3 · B1051.6 · B1060.3 · B1049.7

El 100 vs 1 mide el resultado de la *misión* (llegar a órbita), no el aterrizaje de la primera etapa, que se analiza en la tarea 10.

Tareas 9–10: fallos en 2015 y ranking de aterrizajes

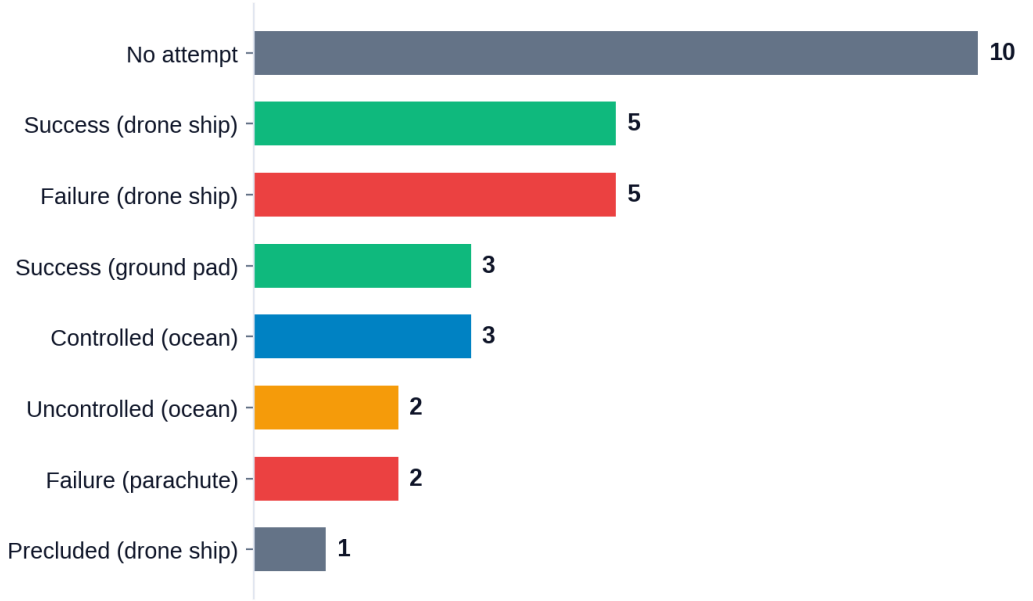
9. Fallos en drone ship durante 2015

```
SELECT substr(Date,6,2) AS Month_Number, Landing_Outcome,
       Booster_Version, Launch_Site
FROM SPACEXTABLE
WHERE substr(Date,0,5)='2015'
  AND Landing_Outcome LIKE 'Failure (drone ship)'
```

MES	RESULTADO	BOOSTER	SITIO
01	Failure (drone ship)	F9 v1.1 B1012	CCAFS LC-40
04	Failure (drone ship)	F9 v1.1 B1015	CCAFS LC-40

10. Ranking de resultados (2010-06-04 a 2017-03-20)

```
SELECT Landing_Outcome, COUNT(Landing_Outcome) AS Total
FROM SPACEXTABLE
WHERE Date BETWEEN '2010-06-04' AND '2017-03-20'
GROUP BY Landing_Outcome ORDER BY Total DESC
```



No attempt 10 · Success (drone ship) 5 · Failure (drone ship) 5 · Success (ground pad) 3 · Controlled (ocean) 3 · Uncontrolled (ocean) 2 · Failure (parachute) 2 · Precluded (drone ship) 1

ANÁLISIS CON SQL · HALLAZGOS

Qué nos dicen las consultas

Hitos y volumen

El primer aterrizaje exitoso en tierra ocurrió el **2015-12-22**. Las 4 plataformas de lanzamiento aparecen en el registro: CCAFS LC-40, CCAFS SLC-40, KSC LC-39A y VAFB SLC-4E.

Misiones

Se registran **100 misiones exitosas frente a 1 fallida**: el cohete llega a órbita casi siempre, pero el aterrizaje de la primera etapa es otro problema.

Transición 2010–2017

Hay 10 vuelos sin intento, 5 aterrizajes exitosos en drone ship y 3 en tierra, frente a 5 fallos en drone ship y 2 en paracaídas: el aprendizaje avanza hacia el éxito en barcazas y tierra.

Evolución de versiones

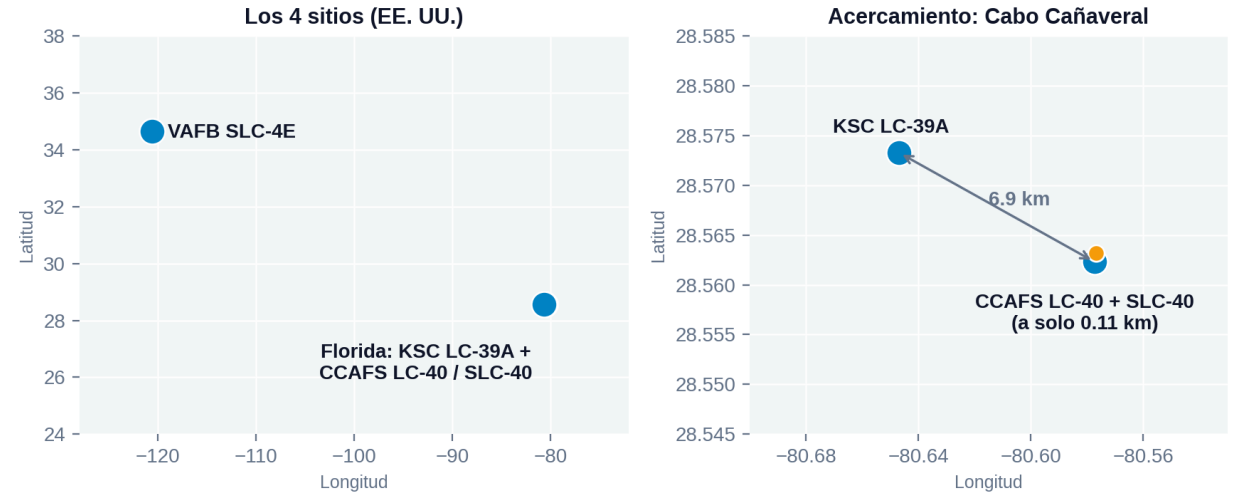
Los fallos en drone ship de 2015 corresponden a F9 v1.1 (enero y abril); los booster con carga máxima son todos de la familia F9 B5, una generación posterior.

Idea clave: La capacidad de aterrizar mejora con el tiempo y la versión del propulsor.

Objetos del mapa interactivo: qué se agregó y por qué

OBJETO FOLIUM	QUÉ HACE	POR QUÉ SE USÓ
folium.Map	Mapa base centrado en NASA Johnson Space Center	Punto de partida para ubicar los sitios en EE. UU.
folium.Circle + Popup	Círculo de 1 km con ventana emergente en cada sitio	Resaltar la ubicación exacta de cada plataforma
Marker + DivIcon	Etiqueta de texto con el nombre del sitio	Identificar cada sitio sin abrir la ventana emergente
MarkerCluster	Agrupa los 56 lanzamientos; verde = éxito, rojo = fallo	Ver qué sitios tienen más éxitos sin saturar el mapa
MousePosition	Muestra latitud y longitud bajo el cursor	Obtener coordenadas de costa, ferrocarril, autopista y ciudad
Marker de distancia + PolyLine	Línea y etiqueta con km entre sitio y punto de interés	Medir y visualizar la proximidad (fórmula haversine)

Tarea 1: ubicación de los sitios de lanzamiento



Representación esquemática construida con las coordenadas del dataset `spacex_launch_geo.csv`.

SITIO	LAT	LONG
CCAFS LC-40	28.5623	-80.5774
CCAFS SLC-40	28.5632	-80.5768
KSC LC-39A	28.5733	-80.6469
VAFB SLC-4E	34.6328	-120.6107

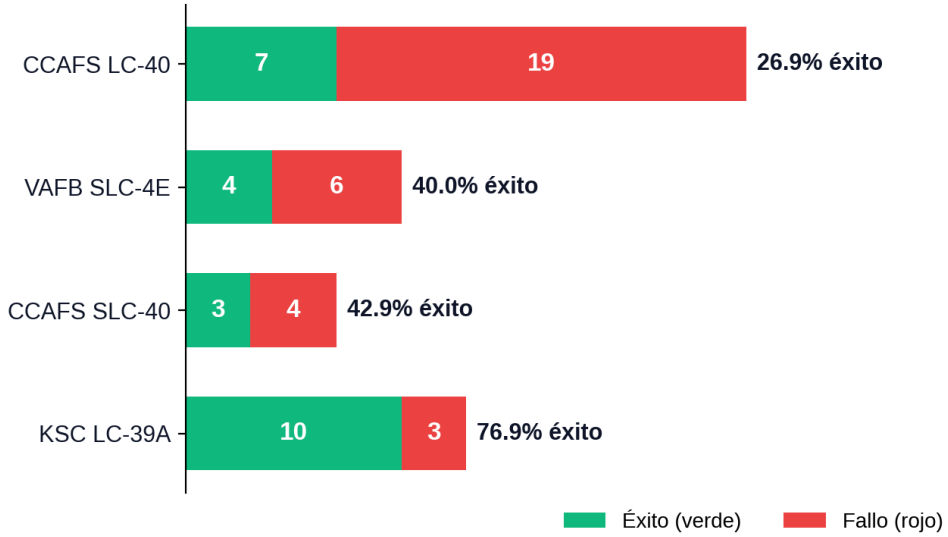
Cómo se construyó el mapa

Mapa base centrado en NASA Johnson Space Center (Houston) y, por cada sitio, un `folium.Circle` de 1 km con ventana emergente y una etiqueta `DivIcon` con el nombre.

¿Cerca del Ecuador? No exactamente: están entre 28.5° y 34.6° N, pero en latitudes bajas de EE. UU., lo que ayuda a aprovechar la rotación terrestre.

¿Cerca de la costa? Sí: los cuatro sitios están junto al océano, lo que permite trayectorias sobre el mar.

Resultados: lanzamientos exitosos (verde) y fallidos (rojo) por sitio



Hallazgo principal

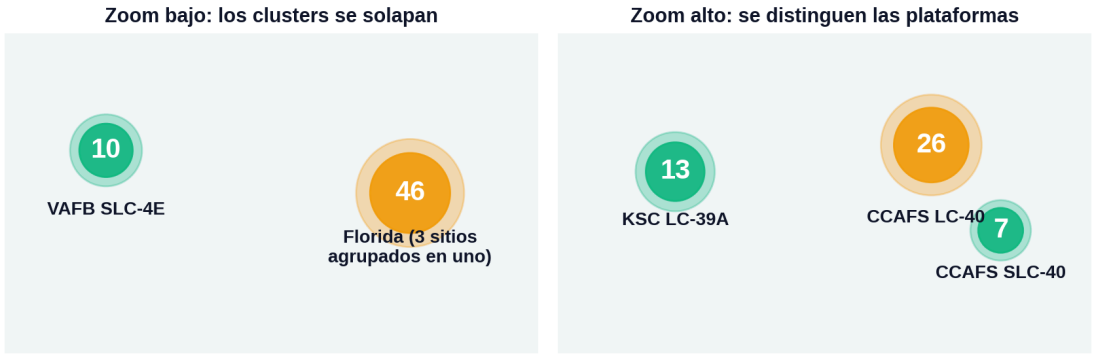
KSC LC-39A tiene la mayor tasa de éxito: **76.9%** (10 de 13). **CCAFS LC-40** tiene la menor: **26.9%** (7 de 26).

Lectura del mapa

Cada marcador es un lanzamiento (56 en total: **24 verdes** y **32 rojos**). En CCAFS LC-40 predominan los rojos, en parte porque concentra los primeros lanzamientos, cuando aún no se dominaba el aterrizaje.

Conteo obtenido de los marcadores del mapa Folium del notebook: CCAFS LC-40 (7 éxitos, 19 fallos), CCAFS SLC-40 (3, 4), KSC LC-39A (10, 3) y VAFB SLC-4E (4, 6).

MarkerCluster y nivel de zoom: por qué los clusters se solapan



Esquema ilustrativo con los conteos reales de cada sitio (13, 26, 7 y 10 lanzamientos).

Solapamiento por zoom

Con el zoom inicial y la corta distancia entre plataformas (CCAFS LC-40 y SLC-40 están a solo **0.11 km**; KSC LC-39A a **6.9 km**), los clusters se solapan y aparecen como un solo agrupamiento de 46 lanzamientos. Al ampliar, se distinguen las plataformas.

Ventaja de MarkerCluster

Permite agregar nuevas características a la representación de cada cluster, como el color o el conteo de éxitos y fallos, sin saturar el mapa.

Tarea 3: cursor del ratón y cálculo de distancias

MousePosition

El plugin `MousePosition` muestra la latitud y longitud bajo el cursor. Así se localizan puntos de interés (costa, ferrocarril, autopista, ciudad) y se anotan sus coordenadas.

Fórmula de distancia (haversine)

Con las coordenadas del sitio y del punto de interés se calcula la distancia en km, usando un radio terrestre de 6,373 km. Después se añade un marcador con la distancia y una `PolyLine` que une ambos puntos.

```
def calculate_distance(lat1, lon1, lat2, lon2):
    R = 6373.0  # radio terrestre (km)
    lat1, lon1, lat2, lon2 = map(radians, [lat1, lon1, lat2,
lon2])
    dlat, dlon = lat2 - lat1, lon2 - lon1
    a = sin(dlat/2)**2 + cos(lat1)*cos(lat2)*sin(dlon/2)**2
    c = 2 * atan2(sqrt(a), sqrt(1 - a))
    return R * c
```

PAR DE PUNTOS	DISTANCIA
CCAFS LC-40 ↔ CCAFS SLC-40	**0.11 km**
CCAFS LC-40 ↔ KSC LC-39A	**6.90 km**
CCAFS LC-40 ↔ punto de costa de ejemplo (28.56367, -80.57163)	**0.58 km**
Florida ↔ VAFB SLC-4E	**≈ 3,820–3,827 km**

Hallazgos de proximidad de los sitios

Costa

Sitios a pocos cientos de metros del mar (por ejemplo, ≈0.58 km en el punto de ejemplo de CCAFS LC-40): las trayectorias y recuperaciones ocurren sobre el océano o plataformas ASDS.

Ferrocarril y autopistas

La cercanía a vías férreas y autopistas facilita el transporte pesado del cohete y sus componentes.

Ciudades

Los sitios se mantienen alejados de zonas densamente pobladas para proteger a la población ante un fallo.

Herramientas aplicadas

`folium.Circle` y `DivIcon` (sitios), `MarkerCluster` (resultados), `MousePosition` (coordenadas), haversine y `PolyLine` (distancias).

Patrón geográfico

Costa, infraestructura de transporte y distancia a ciudades se repiten en los cuatro sitios, lo que explica su elección.

Conclusión: La ubicación se elige para operar sobre el mar, mover cargas pesadas y mantener seguridad pública.

Plotly Dash: componentes, interacciones y por qué

Dropdown de sitio

Opciones: *All Sites* y cada sitio de lanzamiento; por defecto muestra todos.

Gráfico circular (pie)

Todos los sitios: aterrizajes exitosos por sitio. Un sitio: proporción éxito vs fallo.

RangeSlider de carga útil

De 0 a 10,000 kg con paso de 1,000 kg.

Scatter de carga vs resultado

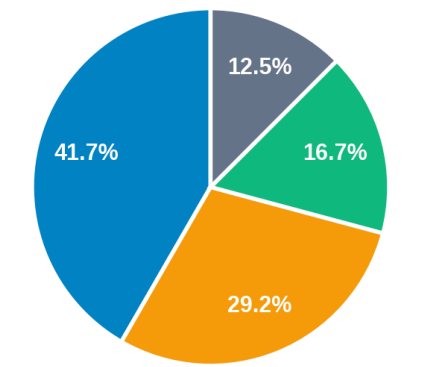
Masa de carga contra `class`, coloreado por *Booster Version Category*.

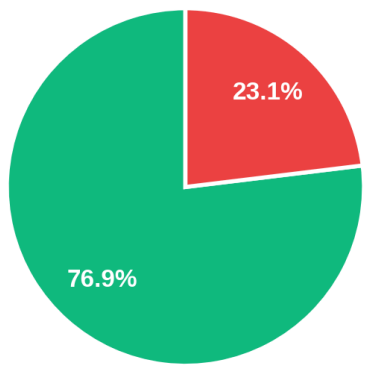
```
# Callback 1: dropdown → gráfico circular
@app.callback(Output('success-pie-chart', 'figure'),
              Input('site-dropdown', 'value'))
def get_graph(entered_site):
    if entered_site == 'ALL':
        # éxitos (class=1) agrupados por sitio
        ...
    else:
        # éxito vs fallo del sitio elegido
        ...

# Callback 2: slider + dropdown → dispersión
@app.callback(Output('success-payload-scatter-chart', 'figure'),
              Input('payload-slider', 'value'),
              Input('site-dropdown', 'value'))
def get_graph_relation(payload, entered_site): ...
```

Archivo en GitHub: `spacex-dash-app.py` (lee `spacex_launch_dash.csv`). El scatter se filtra por rango de carga y sitio.

Resultados del dashboard: gráficos circulares





All Sites

KSC LC-39A concentra el 41.7% de los éxitos, seguido de CCAFS LC-40 (29.2%), VAFB SLC-4E (16.7%) y CCAFS SLC-40 (12.5%).

Sitio con mayor éxito

KSC LC-39A: 76.9% de éxito y 23.1% de fallo, la mejor proporción de los cuatro sitios.

Reproducción de los dos gráficos circulares con los datos de los 56 lanzamientos.

Dispersión carga vs resultado: el control de rango (0–10,000 kg) filtra el gráfico y el color separa las versiones del propulsor, para comparar éxito (class = 1) y fallo (class = 0) por rango de carga.

DASHBOARD OPERATIVO · INTERPRETACIÓN

Cómo se interpreta el dashboard

Con «All Sites»

El pie muestra qué plataforma acumula más éxitos totales; el scatter permite ver cómo se distribuyen los resultados según la masa de carga y la versión del propulsor.

Con un sitio seleccionado

El pie cambia a éxito vs fallo del sitio y el scatter se filtra a sus lanzamientos, para comparar plataformas entre sí.

Carga útil

El control de rango (0–10,000 kg) filtra el gráfico de dispersión para estudiar en qué intervalos de masa se concentran los aterrizajes exitosos.

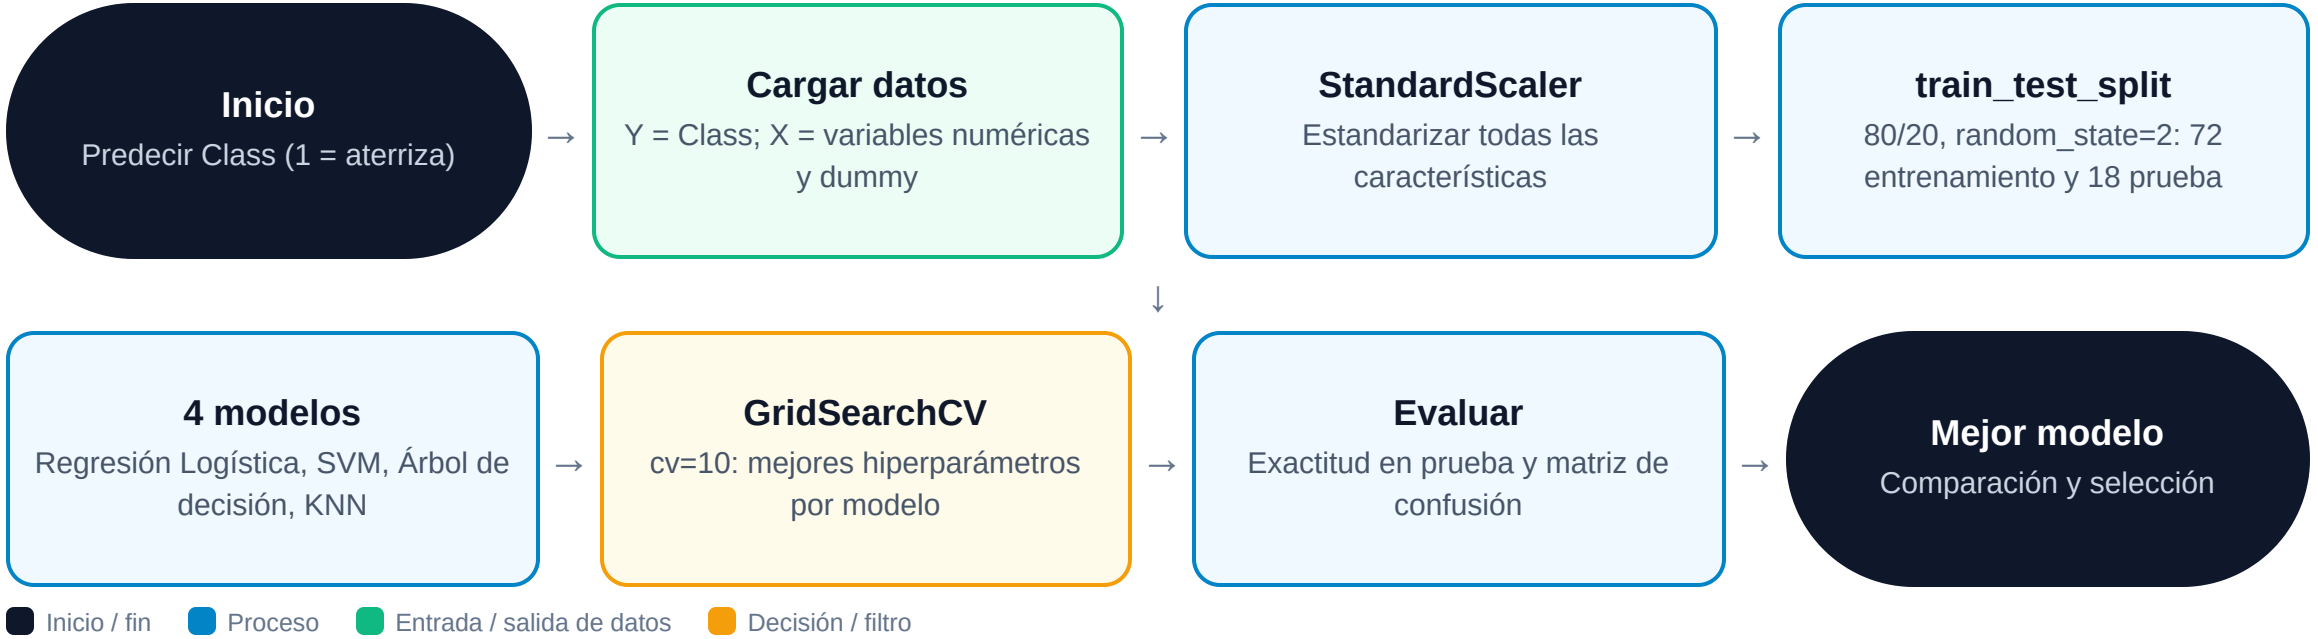
Versión de propulsor

El color por *Booster Version Category* separa las versiones del propulsor para comparar su éxito y fallo.

Conclusión del dashboard: KSC LC-39A: mayor tasa de éxito (76.9%) y 41.7% de los éxitos.

METODOLOGÍA PREDICTIVA

Análisis predictivo (clasificación): diagrama de flujo

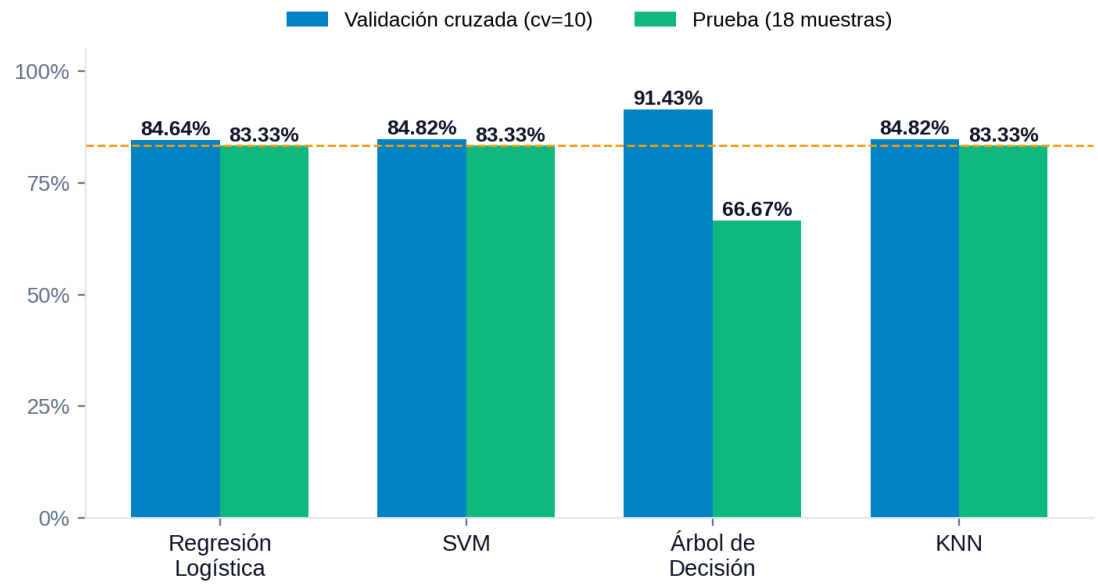


MODELO	HIPERPARÁMETROS EXPLORADOS
Regresión Logística	C ∈ {0.01, 0.1, 1}; penalización l2; solver lbfgs
SVM	kernel (linear, rbf, poly, sigmoid); C y gamma de 0.001 a 1000 (escala logarítmica)
Árbol de decisión	criterio, splitter, max_depth 2–18, max_features, min_samples_leaf, min_samples_split
KNN	n_neighbors 1–10; algoritmo (auto, ball_tree, kd_tree, brute); p ∈ {1, 2}

Mejores hiperparámetros y exactitud de cada modelo

MODELO	MEJORES PARÁMETROS	CV	PRUEBA
Reg. Logística	C=0.01, l2, lbfgs	84.64%	**83.33%**
SVM	kernel sigmoid, C=1, gamma=0.0316	84.82%	**83.33%**
Árbol	entropy, max_depth=6, sqrt, leaf=2, split=2, random	91.43%	**66.67%**
KNN	n_neighbors=10, p=1, auto	84.82%	**83.33%**

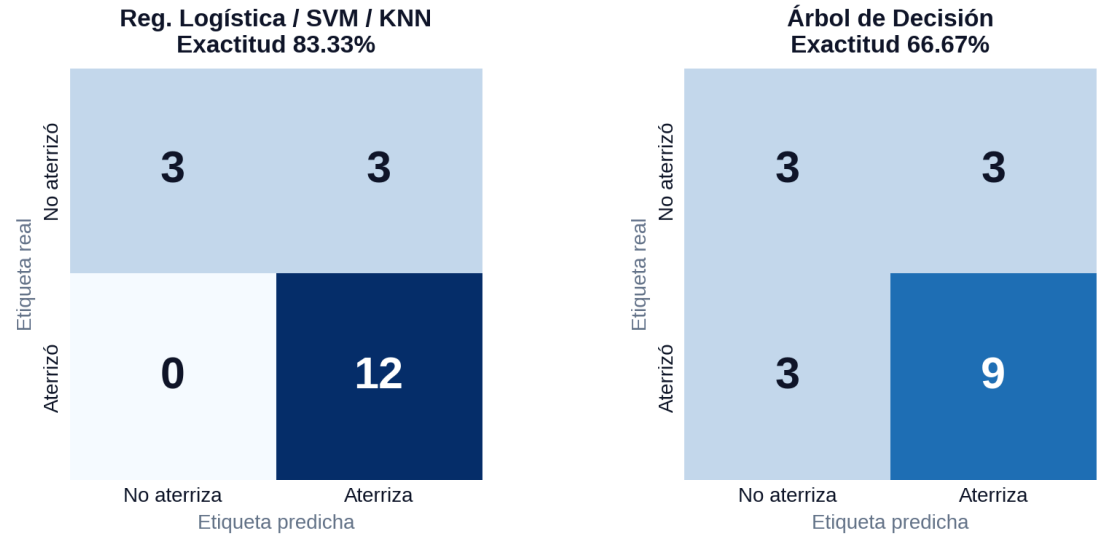
El árbol obtiene la mejor validación cruzada (91.43%) pero cae a 66.67% en prueba: señal de sobreajuste con un conjunto tan pequeño.



Estrategia de modelado: División 80/20 estandarizada con StandardScaler y selección por GridSearchCV (10 pliegues).

MODELADO PREDICTIVO

Matrices de confusión (conjunto de prueba, 18 muestras)



Regresión Logística, SVM y KNN

12 aterrizajes correctamente predichos, 3 no aterrizajes correctos y 3 falsos positivos; ningún falso negativo. Precisión de la clase «aterriza» 80% (12/15) y sensibilidad 100% (12/12).

Árbol de decisión

9 aterrizajes correctos, 3 falsos negativos y 3 falsos positivos: 12 aciertos en 18 casos (66.67%).

El principal error de los modelos son los **falsos positivos**: predecir que aterrizará cuando no lo hará. Para una oferta competitiva, esto implica un riesgo de subestimar el costo.

RESULTADOS

Mejor modelo y lectura de resultados

83.33%
exactitud en prueba: Regresión Logística, SVM y KNN (15 de 18)

66.67%
exactitud del Árbol de decisión (12 de 18)

100%
sensibilidad: ningún aterrizaje real fue omitido

Mejor modelo: Regresión Logística

Tres modelos empatan en prueba (83.33%). Con solo 18 muestras, una diferencia de un caso mueve la exactitud 5.6 puntos, por lo que el empate no es concluyente. Se selecciona la Regresión Logística por ser la más simple e interpretable.

Limitaciones y mejoras

Conjunto reducido (90 misiones), alto costo de falsos positivos. Mejoras: más datos de lanzamientos recientes, validación cruzada repetida y ajuste del umbral de decisión.

DISCUSIÓN

Discusión: respuestas a las preguntas de investigación

¿Cómo afectan la carga y la órbita?

Las órbitas ES-L1, GEO, HEO y SSO alcanzaron 100% de éxito y GTO apenas ≈52%; VAFB SLC-4E no lanzó cargas de más de 10,000 kg.

¿Qué sitio funciona mejor?

KSC LC-39A lidera con 76.9% de éxito frente a 26.9% de CCAFS LC-40, que además concentra los primeros lanzamientos. Todos los sitios comparten costa, acceso por tierra y distancia a ciudades.

¿Cómo evolucionó el éxito?

Pasó de 0% hasta 2013 a ≈84–90% en 2019–2020, con una caída en 2018: la experiencia y las versiones nuevas del propulsor explican la mejora.

¿Se puede predecir el aterrizaje?

Sí: tres de cuatro modelos aciertan 15 de 18 casos (83.33%) y no omiten ningún aterrizaje real.

Implicación: La predicción es útil para estimar costos, pero los 3 falsos positivos piden un margen de contingencia.

CONCLUSIONES Y ENTREGABLES

Conclusiones, insights y recomendaciones

Viabilidad económica

La reutilización de la primera etapa sostiene el costo de $62M frente a $165M+ de otros proveedores; predecir el aterrizaje permite estimar costos reales.

Perfil operativo

El éxito crece con el tiempo y las versiones nuevas; las órbitas ES-L1, GEO, HEO y SSO alcanzan 100% de éxito. KSC LC-39A lidera con 76.9% de éxito (10 de 13); los sitios están junto al mar y lejos de ciudades.

Poder predictivo

Los modelos alcanzan 83.33% de exactitud en prueba, útil para estimar ofertas en licitaciones comerciales.

Recomendaciones

- Usar la predicción como apoyo a la estimación de costos, no como único criterio.
- Incorporar más lanzamientos recientes y variables operativas para reducir los falsos positivos.
- Conectar el control de carga útil del dashboard al gráfico de dispersión para analizar rangos de masa.

REPOSITORIO COMPLETO EN GITHUB
github.com/96092314166/IBM-Machine-Learning-Course

Proyecto final de certificación

APÉNDICE · 1/2

Código y artefactos del proyecto

Notebooks y archivos

- EDA con SQL (SQLite): `jupyter-labs-eda-sql-coursera_sqllite.ipynb`
- Folium y sitios: `lab_jupyter_launch_site_location.ipynb`
- Mapas en Python: `DV0101EN-Exercise-Generating-Maps-in-Python.ipynb`
- Modelado: `SpaceX_Machine_Learning_Prediction_Part_5.ipynb`
- Dashboard: `spacex-dash-app.py`

Código de modelado (extracto)

```
X = preprocessing.StandardScaler().fit_transform(X)
X_train, X_test, Y_train, Y_test = train_test_split(
    X, Y, test_size=0.2, random_state=2)
logreg_cv = GridSearchCV(LogisticRegression(),
    {"C":[0.01,0.1,1],'penalty':['l2'],
     'solver':['lbfgs']}, cv=10)
logreg_cv.fit(X_train, Y_train)
logreg_cv.score(X_test, Y_test)  # 0.8333
```

MarkerCluster y distancias (Folium)

```
mouse_position = MousePosition(position='topright', separator=' Long: ', prefix='Lat:', num_digits=20)
site_map.add_child(mouse_position)
distance = calculate_distance(lat_site, lon_site, lat_poi, lon_poi)
folium.PolyLine(locations=[site_coord, poi_coord], weight=1).add_to(site_map)
```

Resultados SQL completos y fuentes

Ranking de aterrizajes (2010-06-04 a 2017-03-20)

RESULTADO	TOTAL
No attempt	10
Success (drone ship)	5
Failure (drone ship)	5
Success (ground pad)	3
Controlled (ocean)	3
Uncontrolled (ocean)	2
Failure (parachute)	2
Precluded (drone ship)	1

Resumen de resultados

CONCEPTO	VALOR
Carga total NASA (CRS)	45,596 kg
Average_weight (F9 v1.1)	2,928.4 kg
Primer aterrizaje en tierra	2015-12-22
Misiones exitosas / fallidas	100 / 1
Booster (4000–6000 kg, drone ship)	B1022, B1026, B1021.2, B1031.2
Boosters con carga máxima	12 (familia F9 B5)

Fuentes: datos de SpaceX (API REST), Wikipedia (historial de lanzamientos), datasets del curso IBM Data Science Capstone (Skills Network). Las figuras de este documento fueron elaboradas a partir de los resultados de los notebooks del proyecto.